UNER Facultad de Ingeniería

Trabajo final

Universidad: UNER

Facultad: Facultad de ingeniería

Materia: Bioinformática 1

Jefe de cátedra: Juan Manuel Cabrera

Alumnos: Gonzalo Rohrr

Contexto biológico y función principal de la molécula

El receptor del factor liberador de corticotropina tipo 1 (CRF1 o CRHR1) es un receptor acoplado a proteína G (GPCR) perteneciente a la familia B1. Desempeña un rol central en el sistema neuroendocrino de respuesta al estrés al actuar como el mediador primario de las señales iniciadas por el péptido CRF en el eje hipotálamo-hipofisario-adrenal (HPA). La activación de CRF1 promueve el acoplamiento a la proteína Gs heterotrimérica, activando la adenilato ciclasa e incrementando los niveles de AMPc intracelular. Esta cascada induce la síntesis de proopiomelanocortina (POMC) y la consecuente secreción de hormona adrenocorticotropa (ACTH) y glucocorticoides, además de modular circuitos límbicos asociados a la ansiedad y el estado de alerta.

Motivación y justificación de la elección

La elección del complejo CRF1 nace de la alta visibilidad del estrés hoy en día con la alta conectividad y ritmo de vida de la sociedad actual que cada día aumenta, cambios constantes y presiones diarias. Además al ser una diana farmacológica clave para el tratamiento de trastornos psiquiátricos y metabólicos derivados del estrés crónico, el estudio de sus conformaciones activas e inactivas me resulta interesantes. Los avances recientes en criomicroscopía electrónica (cryo-EM) permiten disponer de estructuras tridimensionales de alta resolución (PDB: 6PB0, 6P9X), lo cual brinda información sobre la proteína para aplicar herramientas computacionales de alineamiento, docking molecular y simulaciones de dinámica molecular enfocadas en el diseño racional de fármacos.

Obtención de datos y análisis de secuencia primaria

Scripts utilizados para decargar la secuencia fasta:

```shell
# Ver versión de esearch
esearch -version

# Consulta por identificador PDB y extracción en FASTA
esearch -db protein -query "6P9X[PDB]" | efetch -format fasta > 6P9X_sequences.fasta
```

Búsqueda en formato genbank/GenPet:

```shell
# Descargar registros detallados en formato GenPept/GenBank
esearch -db protein -query "6P9X[PDB]" | efetch -format gp > 6P9X_sequences.gp
```

Enlace desde la base de datos de estructuras (MMDB / PDB)

Para garantizar la extracción de la totalidad de las cadenas proteicas (receptor CRF1 y subunidades de la proteína Gs):

```shell
# Vincular entrada de estructura con sus secuencias proteicas
esearch -db structure -query "6P9X" | elink -target protein | efetch -format fasta > 6P9X_complex_all.fasta
```

Componentes de interés del complejo 6P9X

Para comprender el mecanismo de activación que desencadena la síntesis final del cortisol a través del eje Hipotálamo-Hipófisis-Adrenal (HPA), me interesa analizar la secuencia de tres componentes clave según las bibliografías presentes en el complejo 6P9X:

- **Péptido CRF (corticoliberina):** Unido al receptor para inducir el cambio conformacional.
- **Receptor CRF1 (CRHR1):** GPCR de Clase B1 que transfiere la señal al interior celular.
- **Subunidad $G\alpha_s$:** Proteína G heterotrimérica que intercambia GDP por GTP, activa la adenilato ciclasa, incrementa los niveles de AMPc y activa la PKA, estimulando la liberación de ACTH y la posterior esteroidogénesis de cortisol en la corteza suprarrenal.

Patrones regex del complejo 6P9X

Subunidad $G\alpha_s$ (GNAS / cadena A):

La activación de $G\alpha_s$ requiere la coordinación estricta de GTP y Mg^{2+}.

- **Patrón walker A / P-loop (unión a fosfato del GTP):**
  - Sintaxis PROSITE: `[AG]-x(4)-G-K-[ST]`
  - **Regex:** `[AG].{4}GK[ST]`
  - *Función:* Forma el bucle de unión de los fosfatos α y β del GTP.
- **Patrón switch II / Walker B (hidrólisis de GTP y coordinación de Mg^{2+}):**
  - **Regex:** [DV]-G-G-Q-R o la variante general `[DQE].{2}G`
  - *Función:* Es una de las partes que permite la disociación de $G\beta\gamma$ y la activación de la adenilato ciclasa.
- **Patrón NKxD (especificidad por guanina vs. adenina):**
  - Sintaxis PROSITE: `[NT]-K-x-D`
  - **Regex:** `[NT]K.D`
  - *Función:* Interactúa directamente con el anillo de purina de la guanina.

Receptor CRF1 / CRHR1 (cadena R):

Como miembro de la familia de receptores acoplados a proteínas G de Clase B1, CRF1 posee patrones estructurales característicos en sus dominios extracelular e intracelular.

- **Patrón de N-glicosilación (dominio extracelular ECD):**
  - Sintaxis PROSITE: `N-{P}-[ST]-{P}`
  - **Regex:** `N[^P][ST][^P]`

    - *Función:* asegura el correcto plegamiento, maduración y tráfico del receptor a la membrana plasmática.
- **Patrón de fosforilación por PKA / PKC (desensibilización y regulación):**
    - **Regex (PKA/PKC):** `[RK]{1,2}.[ST]` o `[ST].[RK]`
    - *Función:* Residuo serina/treonina expuesto en los bucles intracelulares (ICL2, ICL3) o cola C-terminal, implicado en el apagado de la señal por arrestinas.
- **Cisteínas extracelulares (puentes disulfuro en ECD):**
    - **Regex:** `C.{5,15}C`
    - *Función:* Mantiene la forma rígida del dominio extracelular para fijar la hormona CRF.

Péptido CRF (cadena P / precursor P06850):

- **Sitio de procesamiento prohormonal (corte por proproteína convertasas):**
    - **Regex:** `[KR][KR]` (ej. `KR` o `RR`)
    - *Función:* Señala los sitios de corte proteolítica en el precursor para liberar el péptido maduro de 41 aminoácidos.

Script para buscar la presencia de patrones en el archivo FASTA descargado, con sus resultado por consola obtenidos:

```
sp|P63092.1|GNAS2_HUMAN RecName: Full=Guanine nucleotide-binding protein G(s) subunit alpha isoforms short; AltName: Ful
l=Adenylate cyclase-stimulating G alpha protein
GAGESGKS
pdb|6P9X|A Chain A, Guanine nucleotide-binding protein G(s) subunit alpha isoforms short
GAGESGKS
```

Shell

```
# 1. Buscar el patrón Walker A (P-loop) en todas las secuencias
perl -ne 'if(/^>(.*)/){$h=$1}elsif(/[AG].{4}GK[ST]/){print "$h\n$& \n"}'
6P9X_sequences.fasta
```

Shell

```
# 2. Identificar sitios de N-glicosilación (N[^P][ST][^P]) en la cadena del
receptor CRF1
perl -ne 'chomp; if(/^>.*CRHR1/){$f=1} elsif(/^>/){$f=0} elsif($f){$seq.=$_}
END{while($seq=~/(N[^P][ST][^P])/g){$pos=pos($seq)-length($1)+1; print "Sitio
de N-glicosilación: $1 en posición $pos\n"}}' 6P9X_sequences.fasta
```

```
Sitio de N-glicosilación: NISG en posición 38
Sitio de N-glicosilación: NASV en posición 45
Sitio de N-glicosilación: NTTN en posición 78
Sitio de N-glicosilación: NGSW en posición 90
Sitio de N-glicosilación: NYSE en posición 98
Sitio de N-glicosilación: NATW en posición 166
```

```shell
# 3. Filtrar dianas de escisión dibásica [KR][KR] en el precursor de CRF
grep -A 2 "CRH_HUMAN" 6P9X_sequences.fasta | grep -P -o "[KR][KR]"
```

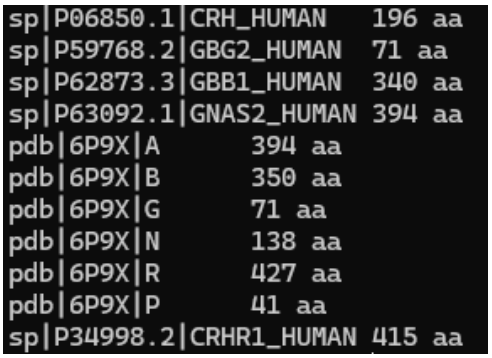
Cantidad de secuencias totales:

```shell
awk '/^>/{count++} END{print "Cantidad total de secuencias:", count}'
6P9X_sequences.fasta
```

Resultado: cantidad total de secuencias 11

Longitud de las secuencias:

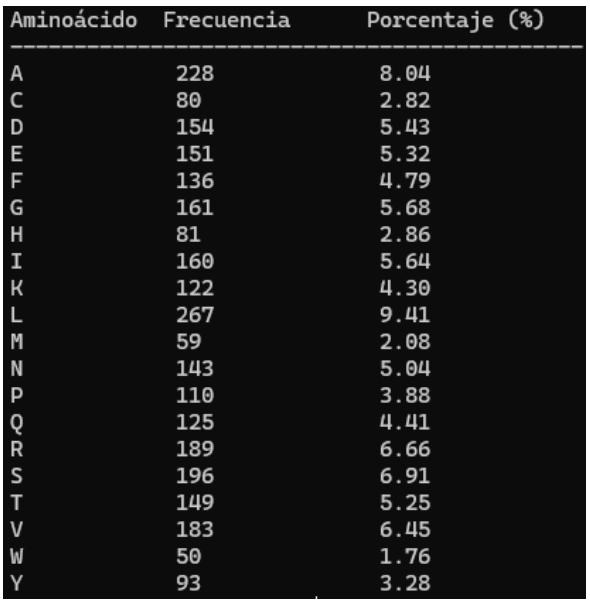
```shell
bioawk -c fastx '{print $name "\t" length($seq) " aa"}' 6P9X_sequences.fasta
```



Composición de aminoácidos:

```shell
bioawk -c fastx '{
    len = length($seq);
    total += len;
    for (i = 1; i <= len; i++) {
        aa = substr($seq, i, 1);
        if (aa ~ /[A-Z]/) count[aa]++;
    }
}
END {
    printf "%-12s %-15s %-15s\n", "Aminoácido", "Frecuencia", "Porcentaje (%)";
    printf "-----------------------------------------------\n";
    for (a in count) {
        printf "%-12s %-15d %-15.2f\n", a, count[a], (count[a]/total)*100;
    }
```

```
}' 6P9X_sequences.fasta
```



Aminoácido	Frecuencia	Porcentaje (%)
A	228	8.04
C	80	2.82
D	154	5.43
E	151	5.32
F	136	4.79
G	161	5.68
H	81	2.86
I	160	5.64
K	122	4.30
L	267	9.41
M	59	2.08
N	143	5.04
P	110	3.88
Q	125	4.41
R	189	6.66
S	196	6.91
T	149	5.25
V	183	6.45
W	50	1.76
Y	93	3.28

Automatización del flujo de trabajo en Bash

Desarrolle un script en Bash (`pipeline_bioinfor2026_6P9X.sh`) que automatiza íntegramente la descarga de secuencias desde NCBI vía Entrez Direct, la búsqueda de motivos funcionales por expresiones regulares y la cuantificación de métricas aminoacídicas con AWK/BioAWK. Esto con el fin de “automatizar” los pasos anteriormente realizados manualmente en Linux Debian.

Shell

```
#!/usr/bin/env bash
# ================================================================================
# SCRIPT PARA AUTOMATIZAR LA PARTE 2 DEL TP FINAL DE BIOINFORMATICA - COMPLEJO
GPCR CRF1 (PDB: 6P9X)
# Pequeña explicacion: Automatizacion integrada para la obtención de secuencias
FASTA/GenPept,
#              caracterizacion de patrones estructurales mediante Regex y
cuantificación
#              de metricas aminoacidicas utilizando AWK y BioAWK.

# Modo estricto: detiene la ejecucion ante fallos, variables no definidas
# o fallos en tuberías (pipelines).
set -euo pipefail

# --------------------------------------------------------------------------------
# 1 DEFINICIÓN DE VARIABLES GLOBALES Y VERIFICACION DE DEPENDENCIAS
# Este paso no se realizaba previamente pero en la actividad 2
# pero como este es un script y lo puedo llegar a reutilizar en un futuro...
```

```
PDB_ID="6P9X"
OUT_FASTA="${PDB_ID}_sequences.fasta"
OUT_GP="${PDB_ID}_sequences.gp"
OUT_COMPLEX="${PDB_ID}_complex_all.fasta"

echo "=== INICIANDO FLUJO DE TRABAJO PARA PDB: ${PDB_ID} ==="

check_dependency() {
    local cmd="$1"
    if ! command -v "$cmd" &> /dev/null; then
        echo "Error: La herramienta '$cmd' no está instalada o no se encuentra
en el PATH." >&2
        exit 1
    fi
}

echo "[+] Verificando herramientas del entorno Linux (Debian)..."
for tool in esearch efetch awk bioawk perl grep; do
    check_dependency "$tool"
done
echo "    Todas las dependencias están disponibles."

# ------------------------------------------------------------------------
# 2 OBTENCION DE DATOS (NCBI ENTREZ DIRECT)
echo -e "\n[+] SECCIÓN 1: DESCARGA DE SECUENCIAS DESDE NCBI (ENTREZ DIRECT)"

# 2.1 Consulta directa a la base de datos 'protein' para obtener secuencias
FASTA asociadas al PDB
echo "    -> Descargando secuencias en formato FASTA..."
esearch -db protein -query "${PDB_ID}[PDB]" | efetch -format fasta >
"${OUT_FASTA}"
echo "       Guardado en: ${OUT_FASTA}"

# 2.2 Consulta directa para extraer el registro anotado en formato
GenPept/GenBank
echo "    -> Descargando registros detallados en formato GenPept (GP)..."
esearch -db protein -query "${PDB_ID}[PDB]" | efetch -format gp > "${OUT_GP}"
echo "       Guardado en: ${OUT_GP}"

# 2.3 Enlace cruzado desde la base de datos MMDB/Structure hacia Protein para
extraer el complejo completo
echo "    -> Recuperando la totalidad de cadenas del complejo macromolecular
via MMDB/elink..."
esearch -db structure -query "${PDB_ID}" | elink -target protein | efetch
-format fasta > "${OUT_COMPLEX}"
echo "       Guardado en: ${OUT_COMPLEX}"

# ------------------------------------------------------------------------
```

```
# 3 IDENTIFICACION DE PATRONES FUNCIONALES (REGEX)
echo -e "\n[+] SECCIÓN 2: IDENTIFICACION DE MOTIVOS ESTRUCTURALES MEDIANTE
REGEX"

# 3.1 Búsqueda del bucle Walker A / P-loop en la subunidad Gs (GNAS)
# Motif PROSITE: [AG]-x(4)-G-K-[ST] | Regex: [AG].{4}GK[ST]
echo "    -> Búsqueda de patrón Walker A / P-loop (unión a GTP):"
perl -ne 'if(/^>(.*)/){$h=$1}elsif(/[AG].{4}GK[ST]/){print "       Encabezado:
$h\n       Coincidencia: $&\n"}' "${OUT_FASTA}"

# 3.2 Búsqueda de sitios de N-glicosilación en el dominio extracelular del
receptor CRF1 (CRHR1)
# Motif PROSITE: N-{P}-[ST]-{P} | Regex: N[^P][ST][^P]
echo "    -> Búsqueda de sitios de N-glicosilación en la cadena del receptor
CRF1:"
perl -ne 'chomp; if(/^>.*CRHR1/){$f=1} elsif(/^>/){$f=0} elsif($f){$seq.=$_}
END{while($seq=~/(N[^P][ST][^P])/g){$pos=pos($seq)-length($1)+1; print "
Sitio N-glicosilación: $1 en posición $pos\n"}}' "${OUT_FASTA}"

# 3.3 Identificación de sitios de procesamiento prohormonal (escisión dibásica)
en el precursor de CRF
# Motif Regex: [KR][KR]
echo "    -> Busqueda de sitios de escision dibasica [KR][KR] en el precursor
de CRF (CRH_HUMAN):"
grep -A 2 "CRH_HUMAN" "${OUT_FASTA}" | grep -P -o "[KR][KR]" | while read -r
match; do
    echo "       Sitio detectado: ${match}"
done

# ------------------------------------------------------------------------
# 4 CÁLCULO DE MÉTRICAS DE ARVO Y COMPOSICIÓN (AWK Y BIOAWK)
echo -e "\n[+] SECCIÓN 3: CÁLCULO DE MÉTRICAS CON AWK Y BIOAWK"

# 4.1 Conteo total de secuencias presentes en el archivo FASTA principal
utilizando AWK
echo -n "    -> "
awk '/^>/{count++} END{print "Cantidad total de secuencias procesadas:",
count}' "${OUT_FASTA}"

# 4.2 Determinación de la longitud individual de cada secuencia usando BioAWK
(módulo fastx)
echo "    -> Reporte de identificadores y longitud de secuencias (residuos de
AA):"
bioawk -c fastx '{print "       ID: " $name "\tLongitud: " length($seq) " aa"}'
"${OUT_FASTA}"

# 4.3 Cálculo de la composición global de aminoácidos (frecuencia absoluta y
porcentaje relativo)
```

```
echo -e "\n    -> Composición aminoacídica global del complejo:"
bioawk -c fastx '{
    len = length($seq);
    total += len;
    for (i = 1; i <= len; i++) {
        aa = substr($seq, i, 1);
        if (aa ~ /[A-Z]/) count[aa]++;
    }
}
END {
    printf "       %-12s %-15s %-15s\n", "Aminoácido", "Frecuencia",
"Porcentaje (%)";
    printf "       ------------------------------------------------\n";
    for (a in count) {
        printf "       %-12s %-15d %-15.2f\n", a, count[a],
(count[a]/total)*100;
    }
}' "${OUT_FASTA}"

echo -e "\n=== Si ves esto se corrio con totalmente con exito ==="
```

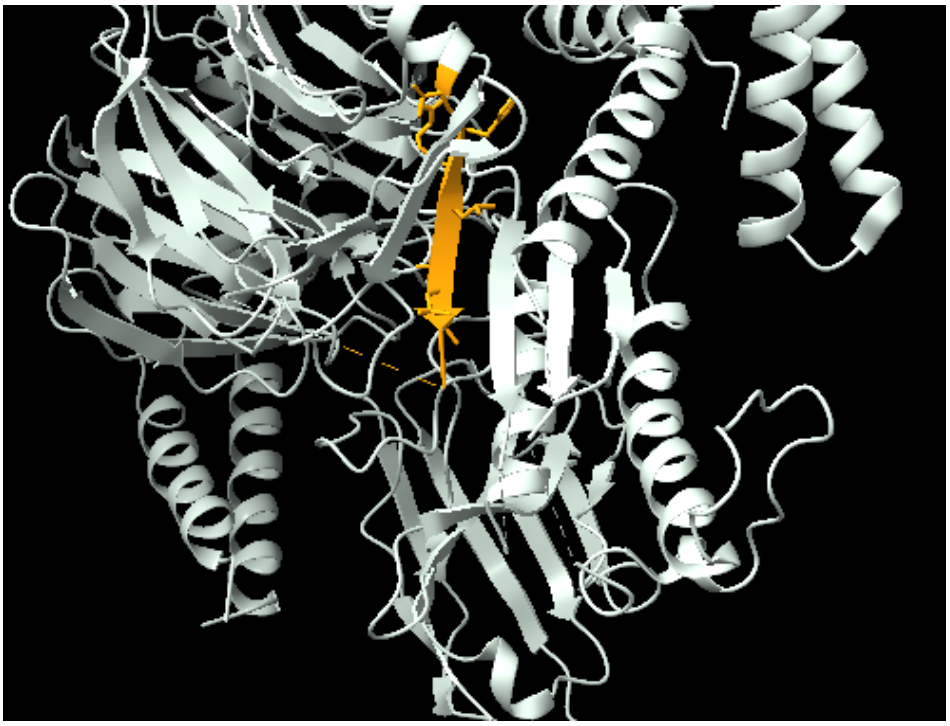
Análisis Estructural 3D

Para este análisis se utilizó la misma estructura mencionada en el trabajo práctico 8 que se encuentra en PDB(link).

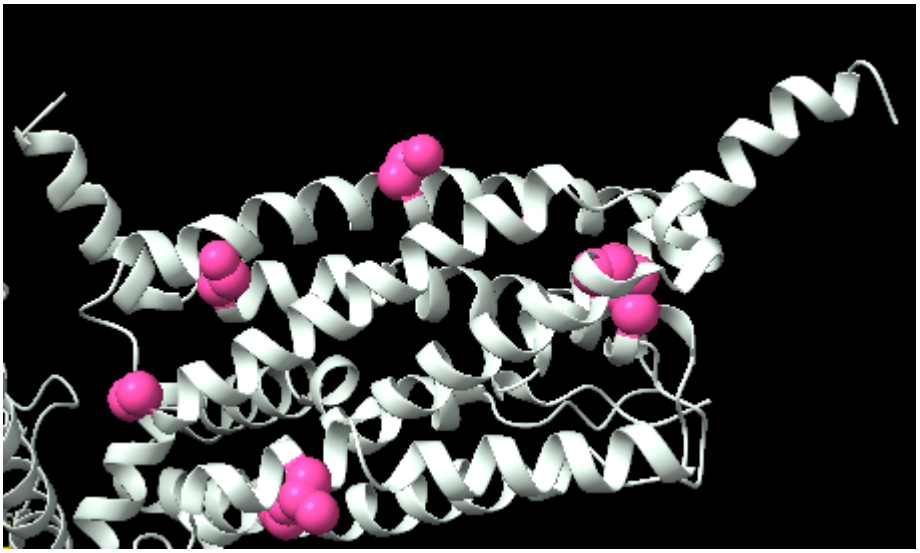
Justificación biológica de las regiones seleccionadas:

- **Patrón Walker A / P-loop en la subunidad G (Cadena A):** La identificación del patrón `[AG].{4}GK[ST]` (residuos 40-47) es importante por constituir el sitio catalítico de unión a los fosfatos del GTP y coordinación del ion Mg^{2+}, evento necesario para la fragmentación de la subunidad G y la siguiente activación de la adenilato ciclasa (Ma et al., 2020; Deussing & Chen, 2018).
- **Cisteínas conservadas en la cadena R (Receptor CRF1):** El resaltado de los residuos de cisteína en el dominio extracelular (ECD) y tramos estructurales del receptor responde a su capacidad de formar puentes disulfuro intramoleculares. Estos enlaces covalentes otorgan la rigidez para el reconocimiento del péptido CRF y la estabilización del receptor GPCR (Ramírez-Perez et al., 2024; Ma et al., 2020).

Patron Walker A / P-loop en subunidad Galpha_s (Cadena A)



Cisteínas / Residuos conservados resueltos en la Cadena R (Receptor CRF1)



-

Bibliografía

1. Ma, S., et al. (2020). Cryo-EM structure of Urocortin 1-bound Corticotropin-releasing factor 1 receptor in complex with Gs protein. *Molecular Cell*, 77(3), 588-598.https://doi.org/10.2210/pdb6PB0/pdb
2. Deussing, J. M., & Chen, A. (2018). The Corticotropin-Releasing Factor Family: Physiology of the Stress Response. *Physiological Reviews*, 98(4), 2225-2280.https://doi.org/10.1152/physrev.00042.2017
3. Ramírez-Perez, F. I., et al. (2024). Structural and Functional Insights into CRF Peptides and Their Receptors. *International Journal of Molecular Sciences*, 25(2), 1102.https://doi.org/10.3390/biology13020120

4. Ma, S., Shen, Q., Zhao, L.-H., Mao, C., Zhou, X. E., Xu, H. E., et al. (2020). Molecular Basis for Hormone Recognition and Activation of Corticotropin-Releasing Factor Receptors. *Molecular Cell*, 77(3), 669–680. https://doi.org/10.1016/j.molcel.2020.01.013